모찌

2026 AI·SW중심대학 디지털 경진대회 본선

스크린샷 · 링크 · 기록을 맡아두는 기억 에이전트

놓치기 쉬운 순간은 쉽게 남기고, 필요한 기억은 쉽게 떠오른다

팀 세얼간이 · 단국대학교 · 송준서 · 박세현 · 이용찬

CONTENTS

목차

01 | 문제와 해결 방향

02 | 작동 구조

03 | 사용 흐름

04 | 실험

05 | 비즈니스 모델

여러곳에 쌓이기만 하고,
확인하지 않는 기록

인스타에서 본 맛집, 나중에 보려던 영상,
채용 공고, 과제 공지 등
저장은 넘치는데 **여러 곳에 흩어져 쌓이기만** 합니다.

그래서 직접 물어봤습니다

20·30대 53명 설문 · 2026.6.29~7.3 · 자체 조사

저장한 기록을 **다시 못 찾은** 적이 있다

79.2% 53명 중 42명

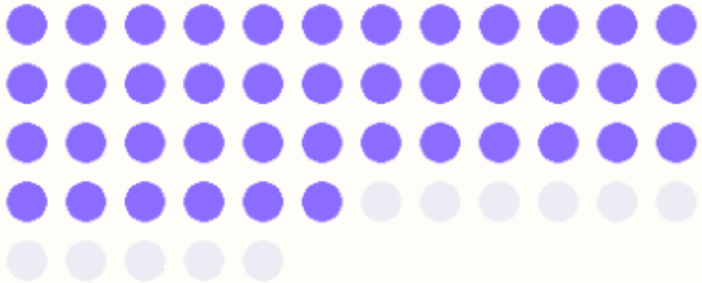

스크린샷을 저장하고 **다시 본 적이 없다**

92.5% 53명 중 49명

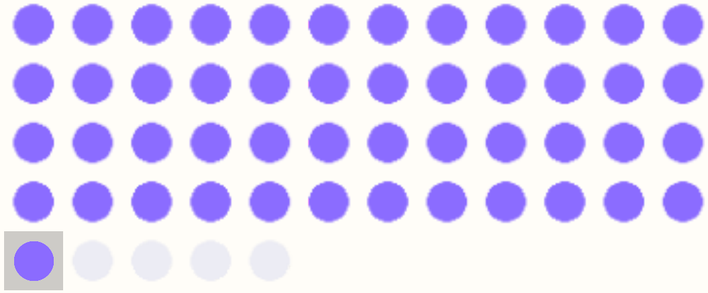

저장은 잘 합니다. 못 찾고, 다시 안 볼 뿐입니다. 응답자 47.2%는 용도 모를 스크린샷 200장 이상 방치

이제 저장만 하면, 모찌가 정리하고 필요할 때 먼저 알려줍니다

흩어져 있던 기록을 쇼핑 · 맛집 · 일정 · 혜택 등 카테고리로 모아두고,
마감처럼 놓치기 쉬운 순간은 때가 되면 **모찌가 먼저 알려줍니다**.

AI 에이전트가 여는 새로운 기록 라이프스타일

'저장하고 잊는' 일상을 '남기면 알아서 떠오르는' 일상으로 - 기록 라이프스타일 자체를 바꿔냅니다.

기존 프로세스

저장한다 ≫ 사용자가 일일이 분류한다 ≫ 사용자가 기억해낸다 ≫ 사용자가 직접 검색한다

만약

스크린샷과 링크를 해석하여,

저장된 의도를 파악해주고,

필요할 때 알려주는

AI 에이전트가 있다면?

모찌 에이전트

저장한다 ≫ 의도 · 의미를 해석한다 ≫ 일정 · 할 일 · 지식 · 기록으로 정리한다 ≫ 필요한 순간 먼저 알려준다

저장 › 해석 · 정리 › 알려주기

남기는 방법은 세 가지

보던 화면 그대로, 앱을 오갈 필요 없이 3초면 모찌에게 들어옵니다.

주 저장 루트

백탭

아이폰 뒷면 두 번 톡

보조 수단

공유시트

SNS · 유튜브 · 브라우저의
공유 버튼에서

보조 수단

앱 내 저장

앱을 열어 직접 추가

저장이 끝나면, 뒤에서 정리됩니다

저장은 즉시 접수, 해석과 정리는 비동기로 — 사용자를 기다리게 하지 않습니다.

저장 완료
즉시 접수 · 3초

비동기 처리

ANALYSIS AGENT

화면을 읽고
스스로 정리합니다

정리 결과 — 4가지

01 4-Intent 복수 선정

한 화면 속 여러 의도를 놓치지 않고 나눕니다

일정 할 일 지식 기록

02 카테고리 선정

주제별로 묶어 나중에 바로 꺼낼 수 있게

쇼핑 # 여행 # 업무

03 요약 · 태그

핵심만 뽑아 검색어에 바로 걸리도록

3줄 요약

04 관련 정보 보강

장소 · 링크 등 빠진 맥락을 스스로 채웁니다

장소 링크

저장 › **해석 · 정리** › 알려주기

왜 네 갈래로 나눴을까요

정보마다 **남겨둘 시간**이 다르니까 —
수명에 맞춰 정리하고, 다르게 알려줍니다

일정

그날이 지나면 끝

아주 짧게 남겨둬요

날짜가 지나면 **자동으로 접어둬요**

예) 엄마 생일

할 일

끝내면 사라져요

끝낼 때까지만

완료하면 **목록에서 비워드려요**

예) 세제 사기

지식

쓸 때까지만

오래되면 한 번 확인

안 쓴 채 오래되면 **아직 필요한지 물어봐요**

예) React 강의 영상

기록

계속 보관

지울 때까지 계속

다시 볼 정보라 **계속 간직해요**

예) 여행 계획, 나중에 볼 영상

저장만 쌓이는 메모리 → **수명에 맞춰 스스로 정리되는 메모리**

정리가 끝나면, 모찌가 먼저 알려줍니다

Analysis Agent
저장된 화면을 이해하는 공통 기반

일정 · 할 일 · 지식 · 기록

Chat Agent

'못 찾는다'를 맡아요

발표 준비 자료 찾아줘

지난주 저장한 자료 3개를 찾았어요.

🔗 원본 기록 🔗 원본 기록

답변마다 근거를 인용 · 일정 등록은 확인 카드 후 실행

Reminder Agent

'다시 안 본다'를 맡아요

모찌 · 지금
저장해둔 '요금제 변경' 오늘이에요. 미리 확인해볼까요?

미리 한 번 — 다시 한 번 — 마감 당일

잊혀질 때쯤 먼저 · 열어본 반응이 다음 알림에 반영

세 에이전트 모두 멀티모달 모델이 필요한 도구를 스스로 골라 쓰는 방식으로 동작합니다

잊어버릴 때쯤, 모찌가 먼저 알려줘요

기억을 떠올리는 주체는 사용자가 아니라 모찌입니다. **망각 곡선**을 기반으로, 이 세 가지 순간에 먼저 알려줍니다.

① 잊혀질 때쯤, 다시

저장한 기억이 흐려지는 시점을 **망각 곡선**으로 예측해 다시 꺼내줍니다

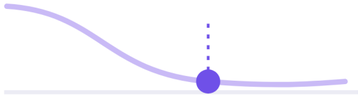

② 비슷한 걸 또 저장하면

새로 저장한 기록과 연관된 예전 기록을 찾아 함께 다시 알려줍니다

③ 마감이 다가오면, 까먹지 않도록

에이전트가 **중요도와 남은 기간**을 보고 알림 빈도와 내용을 스스로 정합니다

같은 일정은 한 카드로 묶고, 6시간 간격 · 과알림 억제로 스팸을 막습니다

작동 구조 · Analysis Agent

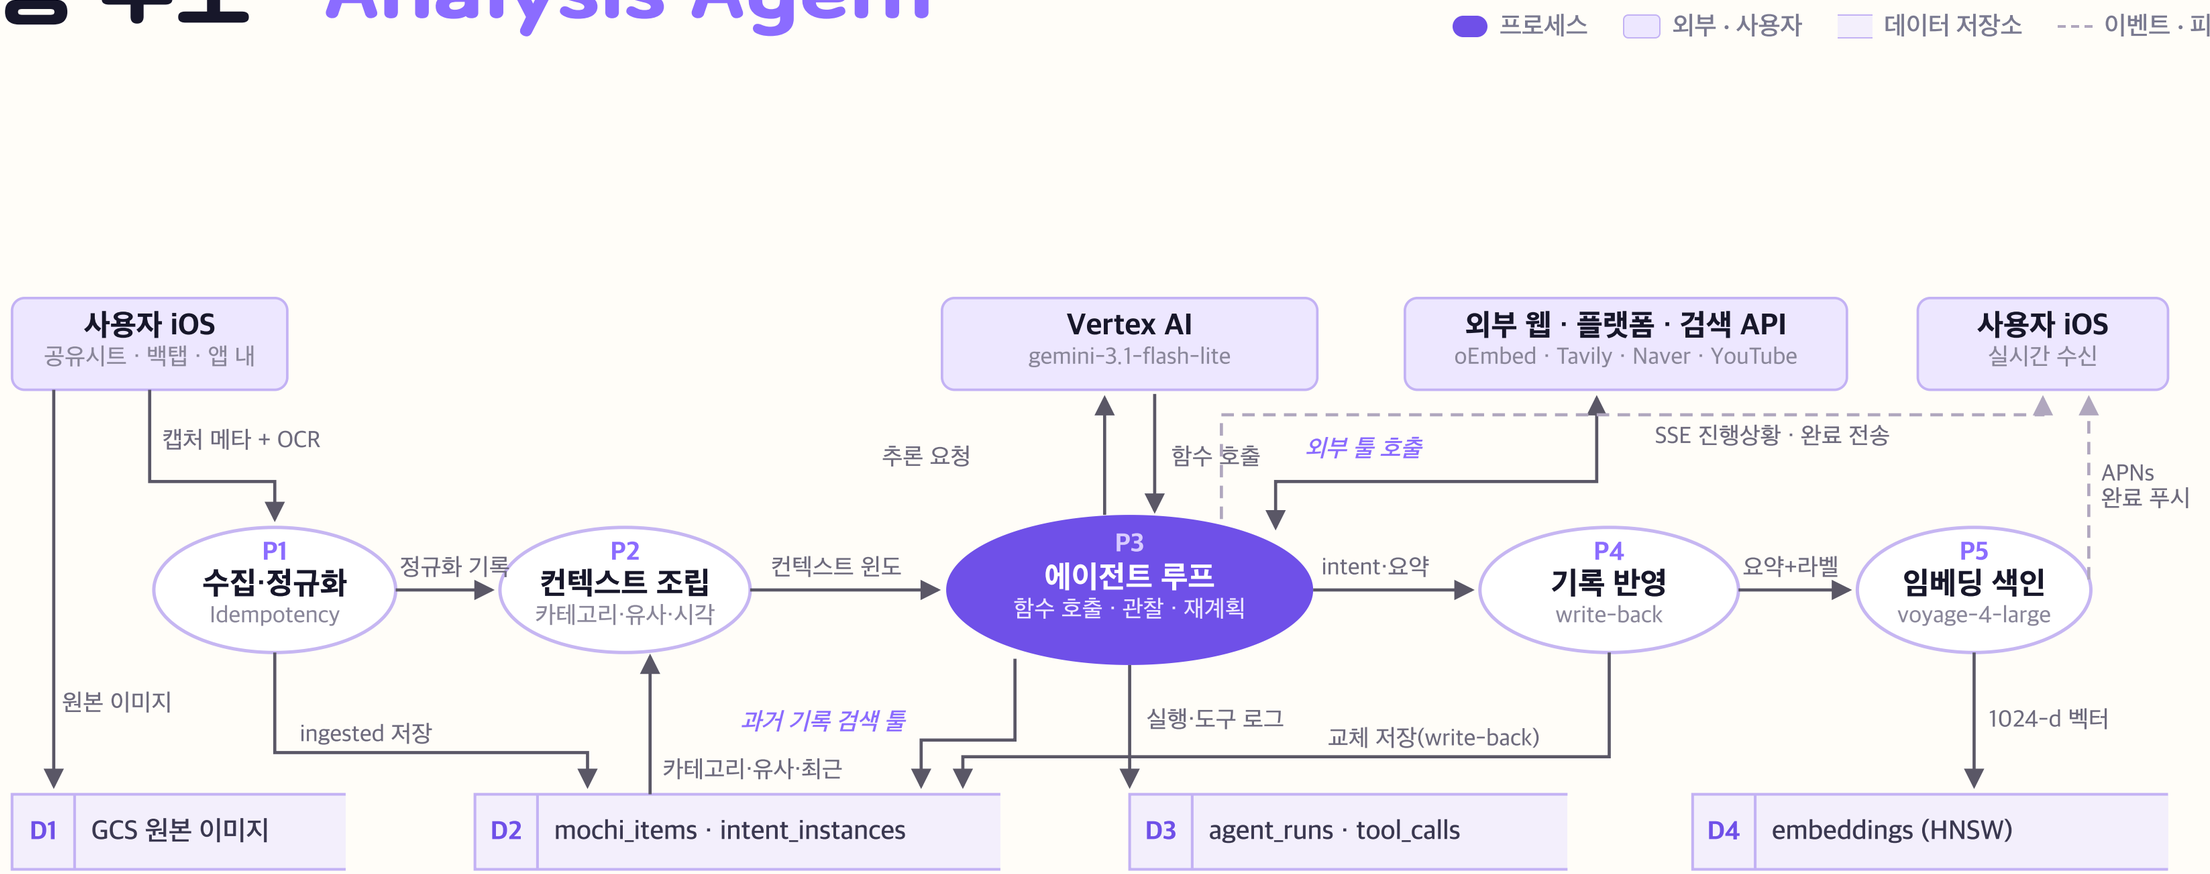

예시 · 캡처 1건 에이킨 타임딜(~7/5) 캡처 저장 → 링크 본문 확인 → '쇼핑' 분류·마감 및 할 일 추출 → "7/5까지 · 19,800원" 요약 → 완료 푸시

작동 구조 · Chat Agent

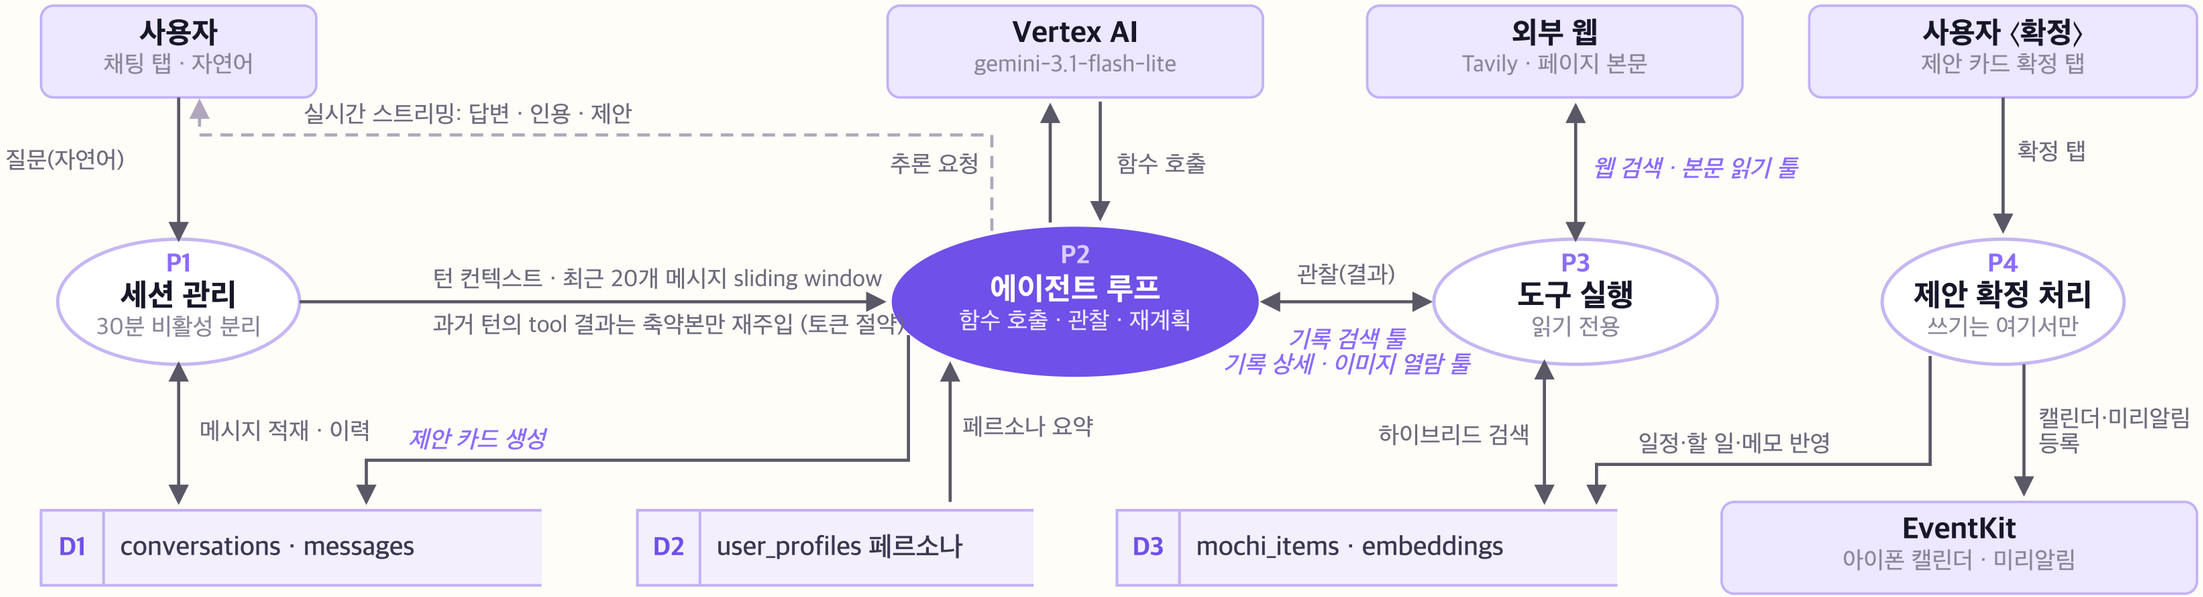

예시 · 대화 1턴 "수강신청 언제야?" → 기록 검색 → "8/6(수) 10시 시작" 근거 인용 답변 → "10분 전에 알려줘" → 제안 카드(8/6 09:50) → 확정 → 미리알림 등록

작동 구조 · Reminder Agent

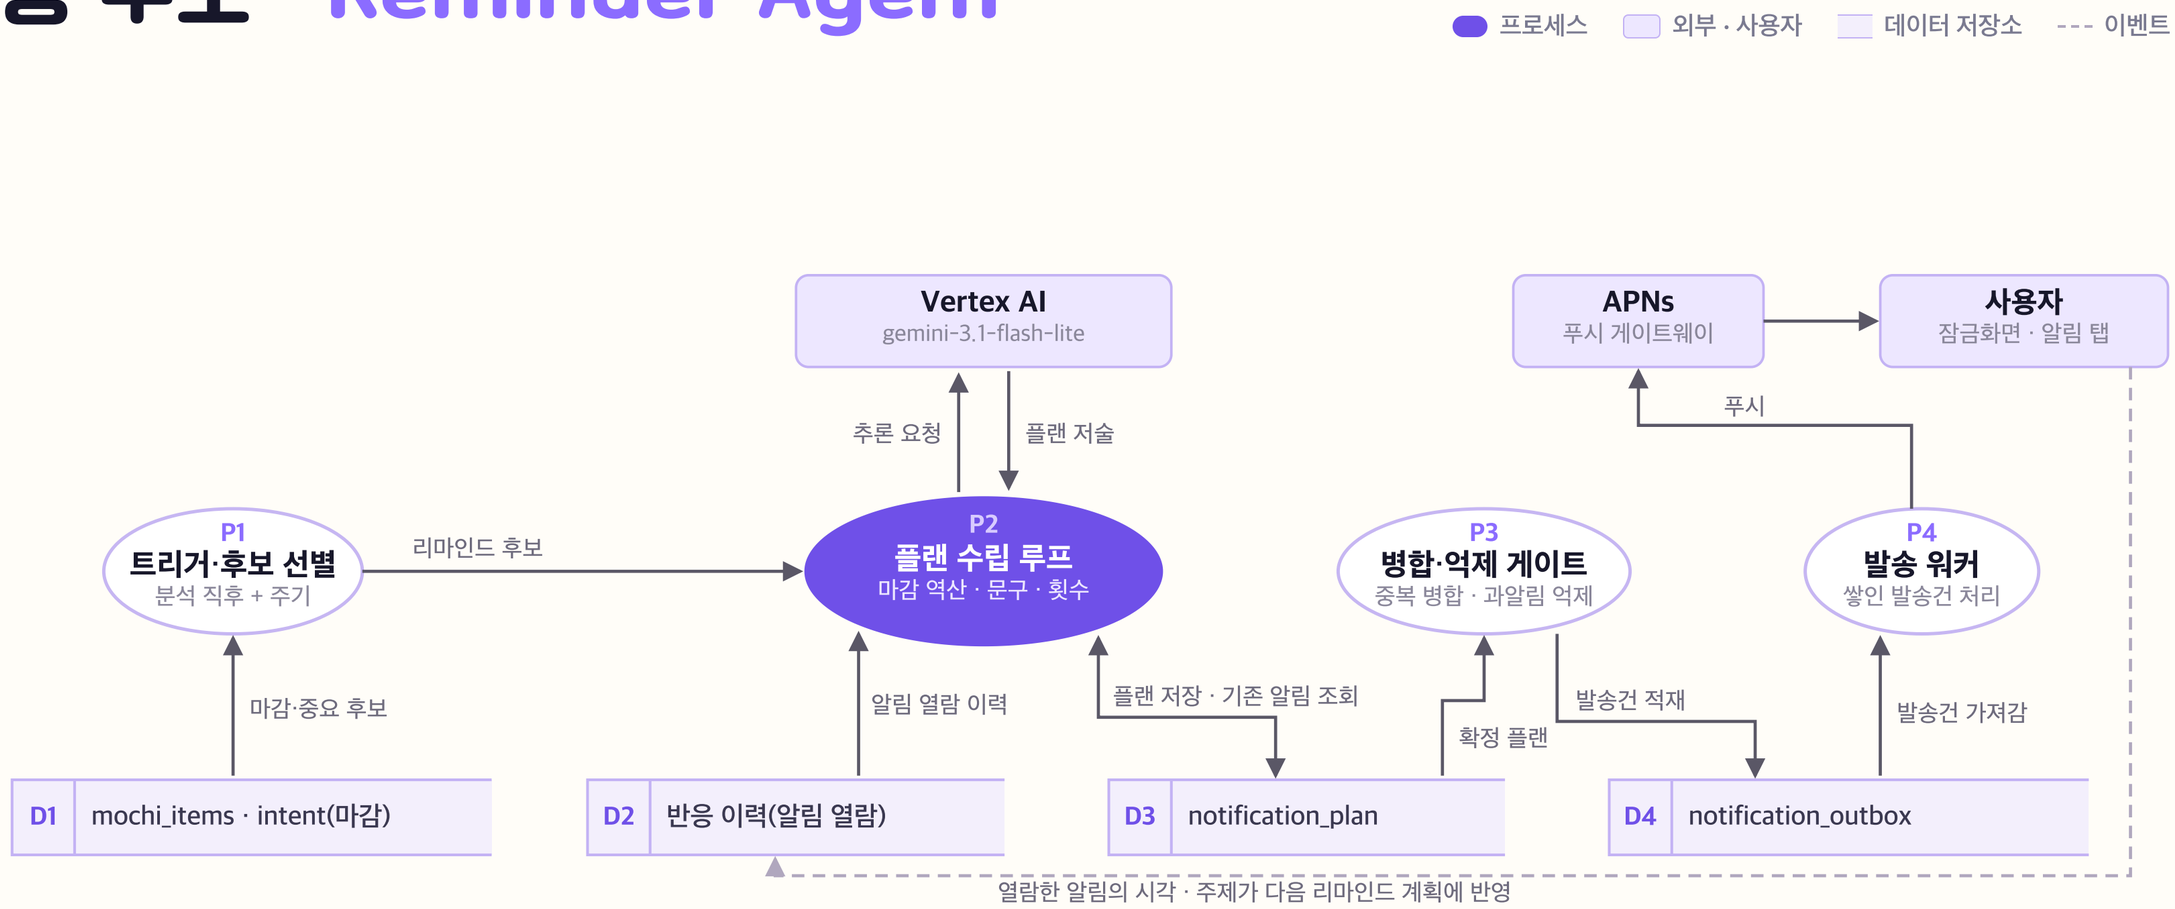

예시 · 알림 1건 마감 7/5 확인 → 플랜 D-3 · D-1 두 번 → 같은 날 알림 묶어 발송 → 잠금화면 푸시 → 열람 시각이 다음 회차의 기준점

01 저장

보내기만 하세요, 3초면 끝나요

보던 화면에서 뒷면 두 번, 앱을 오갈 필요 없이

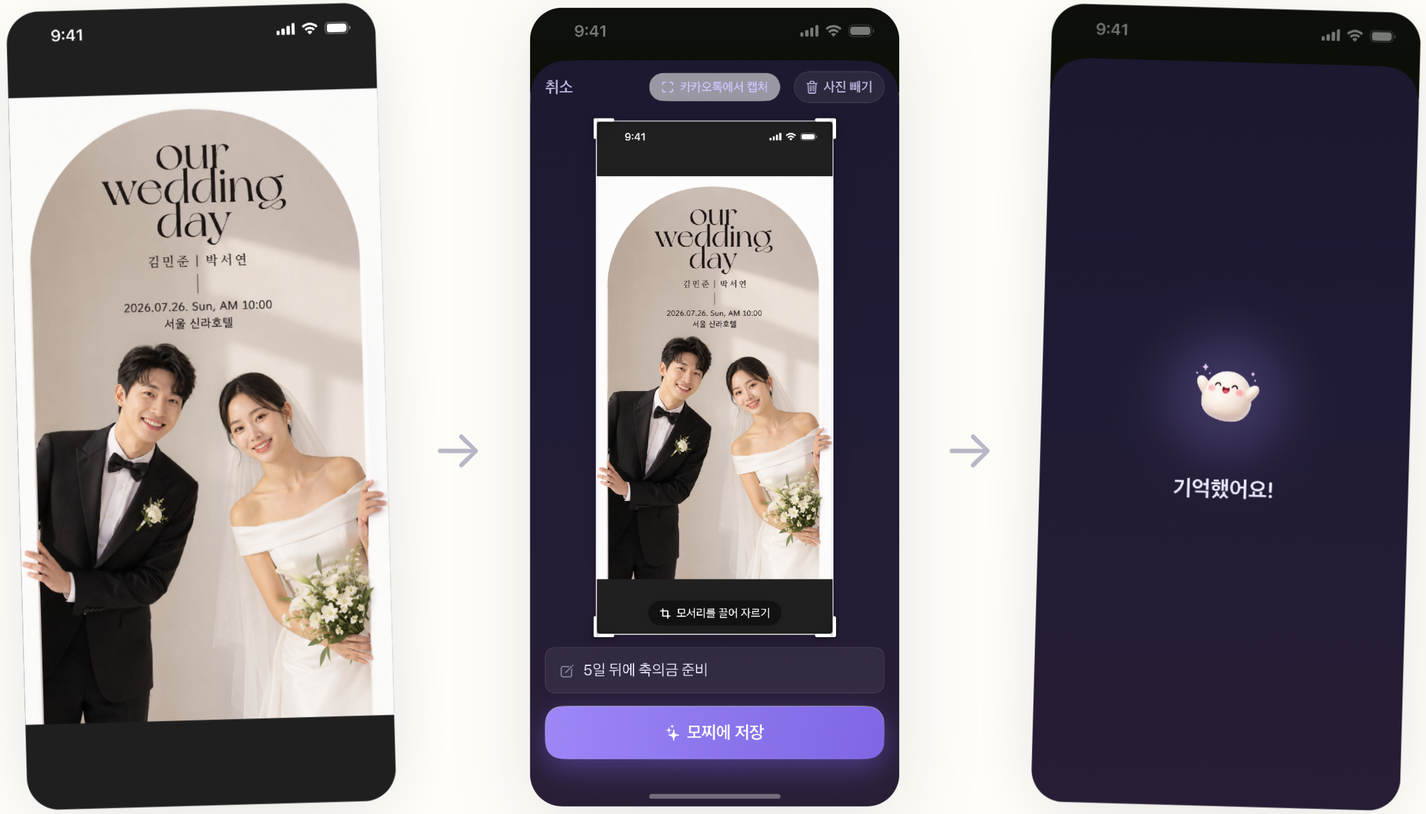

1 보던 화면

2 뒷면 두 번 탭

3 캡처 확인 · 저장

SNS · 유튜브에서는 공유 버튼으로도 똑같이 모찌에게 보낼 수 있어요

02 정리

스크린샷 한 장이 살아있는 기록으로

청첩장 한 장을 보내면

✓ **분류하고 요약해요**
누구의 · 언제 · 어디서 결혼식인지 한 줄로 정리

✓ **예식장 지도를 붙여요**
예식장 위치를 네이버 · Google Place와 교차 확인

✓ **일정 · 할 일도 함께 만들어요**
'결혼식 참석' 일정과 '축의금 준비' 할 일을 자동으로

02 정리

청첩장 한 장이 일정 · 할 일로

청첩장을 저장하면

날짜 · 시간 · 장소 · 이름을 읽어내요
Multimodal AI 가 읽고, Vision OCR 이 보충하여 추출

일정과 할 일을 함께 만들어요
'결혼식 참석'(일정) + '축의금 준비'(할 일) 생성

iOS 캘린더 앱 · 미리알림 앱에 자동 저장
EventKit으로 기본 앱에 등록 — 앱을 다시 열지 않아도 반영돼요. '결혼식 축의금 준비' 할 일과 '김민준 | 박서연 결혼식 참석' 일정이 그대로 저장됩니다.

추출 파이프라인 OCR · 필드 추출 → intent 분류 → 마감 역산 → 캘린더, 미리알림에 저장

03 찾기

물어보면, 저장된 기록을 기반으로

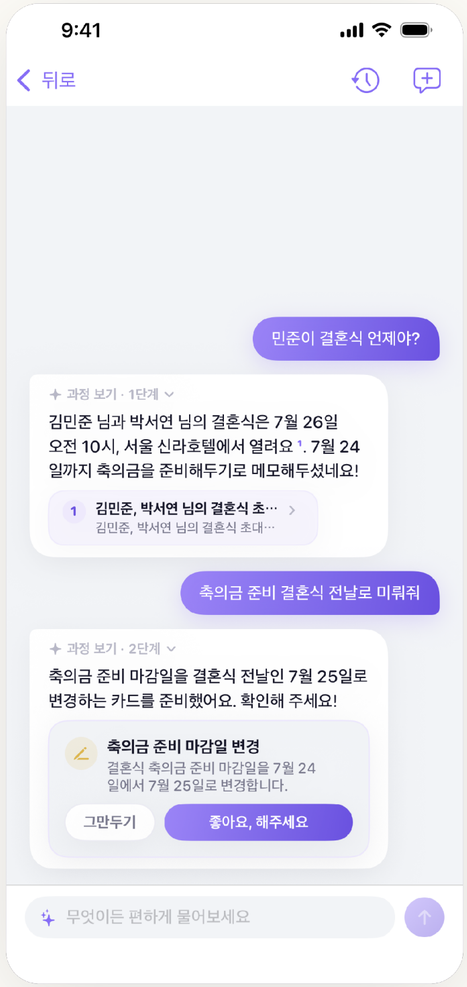

채팅 · 내 기록으로 답해요

이렇게 물으면 **"민준이 결혼식 언제였지?"**

이렇게 답해요 **7월 26일 오전 10시, 신라호텔에서 열려요. 축의금도 잊지 말고 잘 챙기시길 바라요!**

✓ **답변마다 원본을 인용해요**
지어내지 않고 저장된 청첩장 기록을 근거로 — 탭 한 번이면 원본 확인

✓ **"축의금 준비 전날로 미뤄줘"까지 실행**
확인 카드 → 사용자가 확정해야 실제 등록

동작 RAG · 도구 호출 **SSE 스트리밍**

search_items → get_item_detail → 기록 기반 답변 → `propose_item_update`

03 찾기

단어가 달라도 찾아드려요

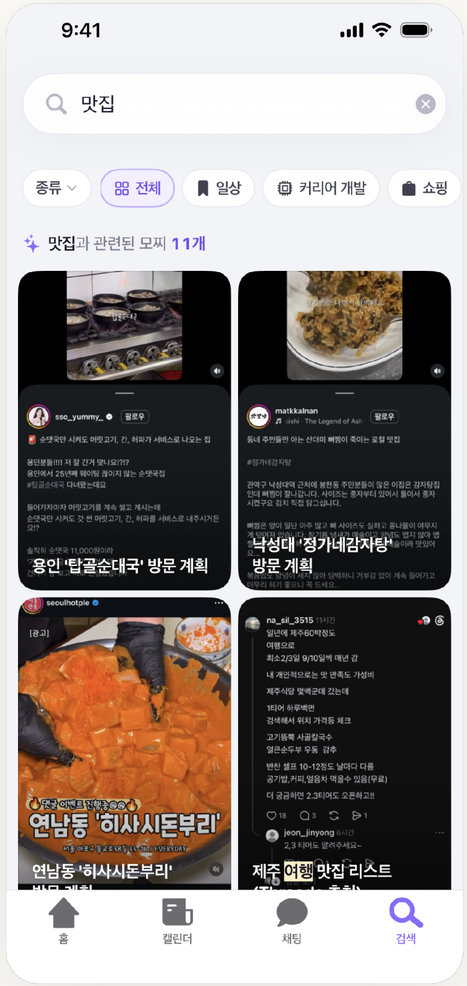

의미로 찾아요

이렇게 쳐도 **'맛집'**

이게 나와요 **'용인 '탑골순대국' 방문 계획'**

어떻게 이게 되나요?

키워드 검색 BM25
글자가 같은 기록

+

Vector Search voyage 1024-d
뜻이 비슷한 기록

→

리랭커로 재정렬
하이브리드 융합

두 결과를 합치고 리랭커가 순위를 다시 매겨, 맨 위 결과의 적중을 높입니다

성능 recall@25 0.958 · pgvector · HNSW 인덱스 · 한번 조회당 25건

04 홈 화면

앱을 열면, 모찌가 먼저 꺼내줘요

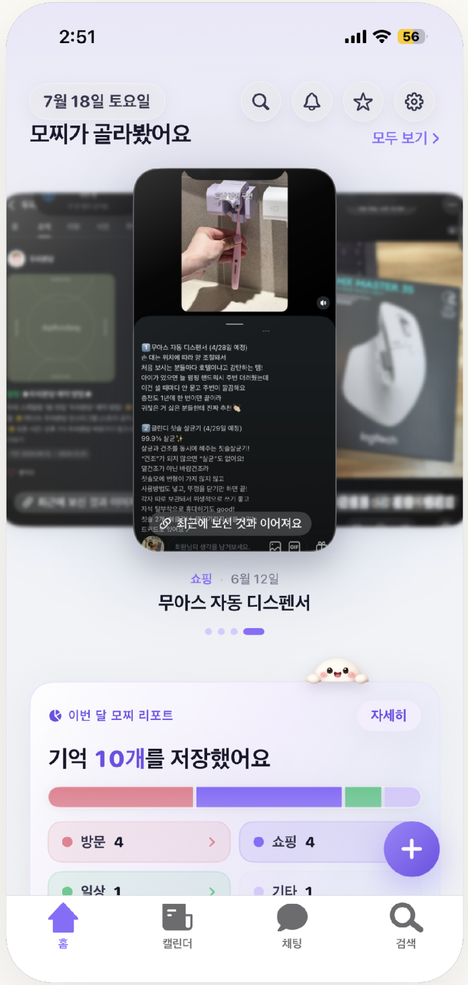

다시 보면 좋을 기억

모찌가 골라봤어요

다시 보면 좋을 기억을 **먼저 골라** 보여줍니다. 잊고 있던 저장이 자연스럽게 눈에 들어옵니다.

이번 달 모찌 리포트

얼마나 모였는지 한눈에

이번 달 무엇을 얼마나 저장했는지 **종류별로 요약합니다**

찾으러 들어오지 않아도, 홈을 여는 것만으로 모찌가 이미 정리해둔 걸 만납니다

05 기록 상세

저장한 기록이 다음 행동으로 이어져요

기록 하나를 열면 모찌가 **관련 링크**를 정리하고, **비슷한 기록**까지 함께 꺼내줍니다.

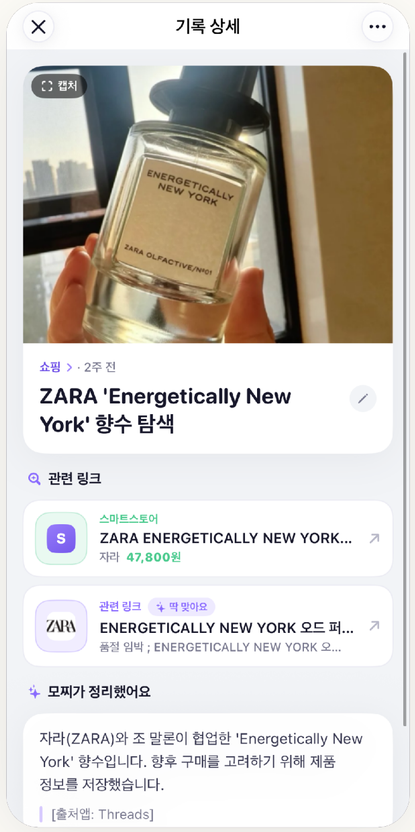

쇼핑 기록 최저가 47,800원

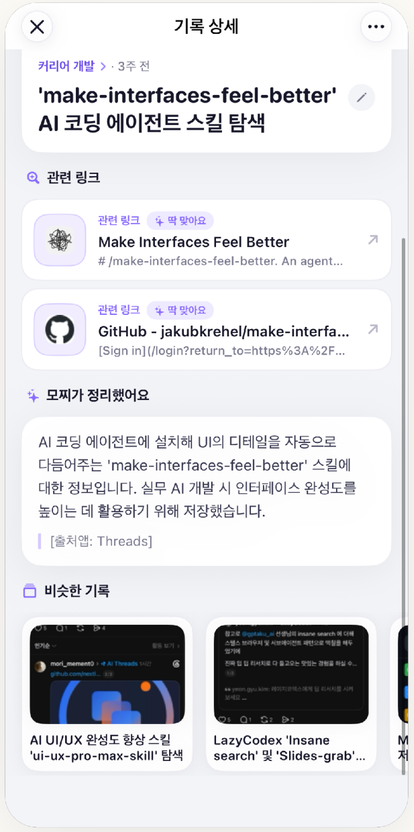

개발 · 정보 기록 비슷한 기록

관련 링크를 자동으로 정리

원문·문서 링크를 찾아줘요.

바로 구매할 수 있는 링크까지

스마트스토어·브랜드몰 가격을 가져와 사용자가 찾을것을 미리 준비해요

비슷한 기록을 함께

지금 보는 기록과 연관된 **과거 저장**을 보여줘 기억을 되짚어줘요

05 개인화

쓸수록, 점점 더 나에게 맞춰져요

회수 알림부터 분류 · 검색까지, 모찌는 나의 사용 패턴을 계속 반영합니다.

01

저장 습관을 반영

내가 주로 무엇을 어떻게 저장하는지를 새 기록 분석에 반영해요

저장 패턴 분석

02

열어본 반응을 반영

알림을 언제, 무엇을 열었는지가 다음 알림 계획에 반영돼요

언제 열었나 무엇을 열었나

↻ 다음 알림 계획에 반영

03

관련 기록 제안

새 기록과 연관된 과거 기록을 찾아 함께 꺼내줘요

유사도 검색 연결

04

내 분류 이름 유지

새로 지어내지 않고, 내가 쓰던 카테고리 이름을 계속 써요

#쇼핑 #맛집 #일정

슬라이딩 윈도우 참조 · 주기적 정규화

이런 행동이 신호가 돼요 알림 시각 옮기기 · 이 항목 알림 끄기 · 이 기억 그만 보기 · 분류 직접 수정

프라이버시

민감한 화면은 기기 밖으로 나가지 않아요

① 서버로 나가기 전, 기기 안에서 감지

주민번호 · 카드번호 · 계좌 · 인증번호 · 비밀번호

② 감지되면, 선택은 사용자가

1. **원본 그대로 저장**
2. **민감한 곳만 가리고 저장**
   블러를 기기에서 입혀, 서버에는 가려진 이미지만 올라갑니다
3. **이 기기에만 보관**

분석에 쓴 OCR 텍스트는 추론 직후 서버 · 단말 양쪽에서 삭제됩니다

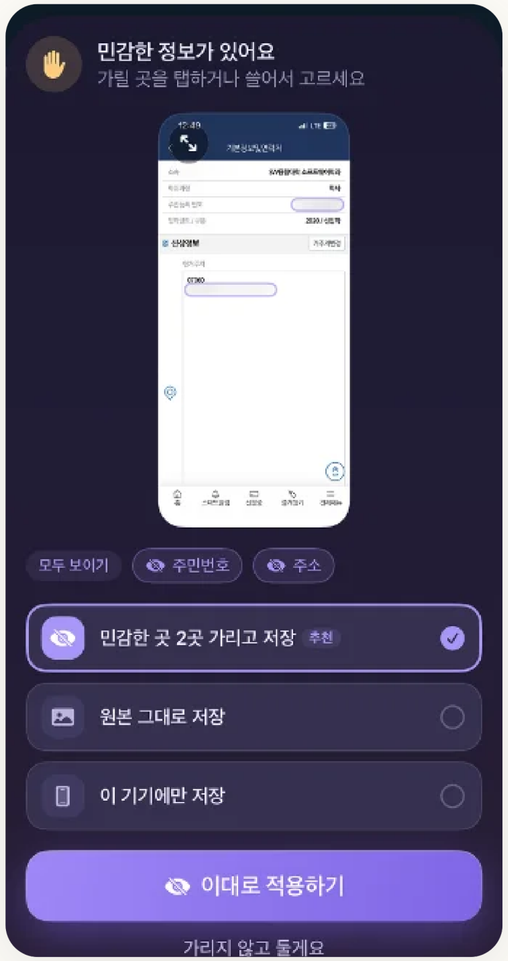

Agent 의사결정과 실측 근거

핵심 Agent 동작은 감이 아니라 같은 조건의 비교 실험으로 결정했습니다. 각 결정은 사용자 가치와 바로 연결됩니다.

Analysis Agent

저장만 해도 의도·날짜가 안정적으로 정리된다

검증한 질문 — 프롬프트·스키마 개편이 일부 예시가 아니라 전체 품질을 실제로 높였는가?

91.3% → **95.6%**

골든 eval 통과율 · 229케이스×3회 (v28→v29)

반영 — 실패 유형 기준으로 분류 규칙·why 필드 보강한 v29 채택

Search · RAG Tool

정확한 단어를 몰라도 관련 기록이 상위에 남는다

검증한 질문 — 같은 검색 후보 조건에서 reranker가 상위 순위 품질을 개선하는가?

0.476 → **0.872**

상위 3개 회수율 R@3 (Vector → +rerank-2.5)

반영 — voyage-4-large@1024 + 요약·태그 + rerank-2.5 조합 채택 · MRR 0.560→0.882

카테고리 일관성

같은 주제는 매번 같은 이름으로 쌓인다

검증한 질문 — 전체 이력 어휘를 약한 힌트로 주면 같은 주제의 이름 재사용이 실제로 오르는가?

0/24 → **24/24**

동일 주제 이름 재사용 · 균형 A/B (McNemar p=0.000488)

반영 — 전체 이력 어휘를 약한 힌트로 주입 · false reuse 4/16은 월간 repair로 관리 (추가 LLM·cron 0)

10+ 비교 실험

저장·검색·회수 전 영역에서 같은 조건 비교로 의사결정 — 이 슬라이드는 대표 3개

골든셋 회귀 · 추출 전략 A/B/C · intent 스키마 · 카테고리 일관성 · RAG rerank · TOP_K 8→25 · 하이브리드 BM25/Vector/RRF · 알림 planner A/B · proactive bundling · 콜드스타트 · 알림 weight judge

커지는 시장, 닿을 수 있는 기회

TAM → SAM → SOM

TAM ₩20.0조
글로벌 노트 · 기록 앱

SAM ₩276억
국내 20~30대 유료

SOM ₩2.16억
3년차 목표

SOM = 유료 8,000명 × ARPPU ₩2,245 × 12개월

시장 성장성

글로벌 노트·기록 시장 연평균 +20.5% 성장

목표 유입 퍼널 · 12개월

0–6개월 오가닉 시딩(타인 추천 의향 86.8%) · 6–12개월 Apple Search Ads + Meta Ads

990원으로도 남는 구조

요금제

FREE	₩0
LITE 하루 33원	₩990
PRO	₩2,900
MAX	₩4,900

예상 가입 LITE 50 : PRO 35 : MAX 15 → ARPPU ₩2,245

무료로 습관을 들이고, 더 쓰는 사용자가 자연스럽게 유료로
— 대부분 990원 LITE로 충분합니다

단위 경제성

변동비 ₩260 공헌이익 ₩1,985

88% 공헌이익률 · ARPPU ₩2,245 기준 · LTV÷CAC 4.2×

3개년 매출 · 리텐션

30일 잔존율 목표 20% (앱 평균 7%의 2.9배)

놓치기 쉬운 순간은 쉽게 남기고,
필요한 기억은 쉽게 떠오른다

저장은 3초, 나머지는 모찌가 합니다

감사합니다 · 팀 세얼간이 · 송준서 · 박세현 · 이용찬

APPENDIX

부록 · 질문 영역별 목차

문제 · 효과

페르소나 · 설문 · KPI

"누가 겪나요?" · "뭐가 좋아지나요?"

A1 ~ A4

아키텍처 · 에이전트 · 도구

"다 구현했나요?" · "AI가 어떻게 이해하죠?"

A5 ~ A6

검색 · 실험

"검색이 뭐가 다르죠?" · "수치 근거는요?"

A7

프라이버시

"개인정보는 안전한가요?"

A8

신뢰성 · 보안

"장애나 공격에는요?"

A9

데모웹 · 사용자 흐름

"네트워크 끈기면요?" · "실제로 어떻게 쓰죠?"

A10

시장 · 수익 · 성장

"돈이 되나요?" · "어떻게 성장하죠?"

A11 ~ A12

출처 · 한계 · 로드맵

"라이선스·출처는?" · "안 되는 건 뭐예요?"

부록 · 문제 검증

“설문은 어떻게 했나요?”

20대 53명 · 2026.6.29~7.3 · 자체 조사 — 네 지표 모두 ‘저장 다음’의 실패를 가리켰습니다

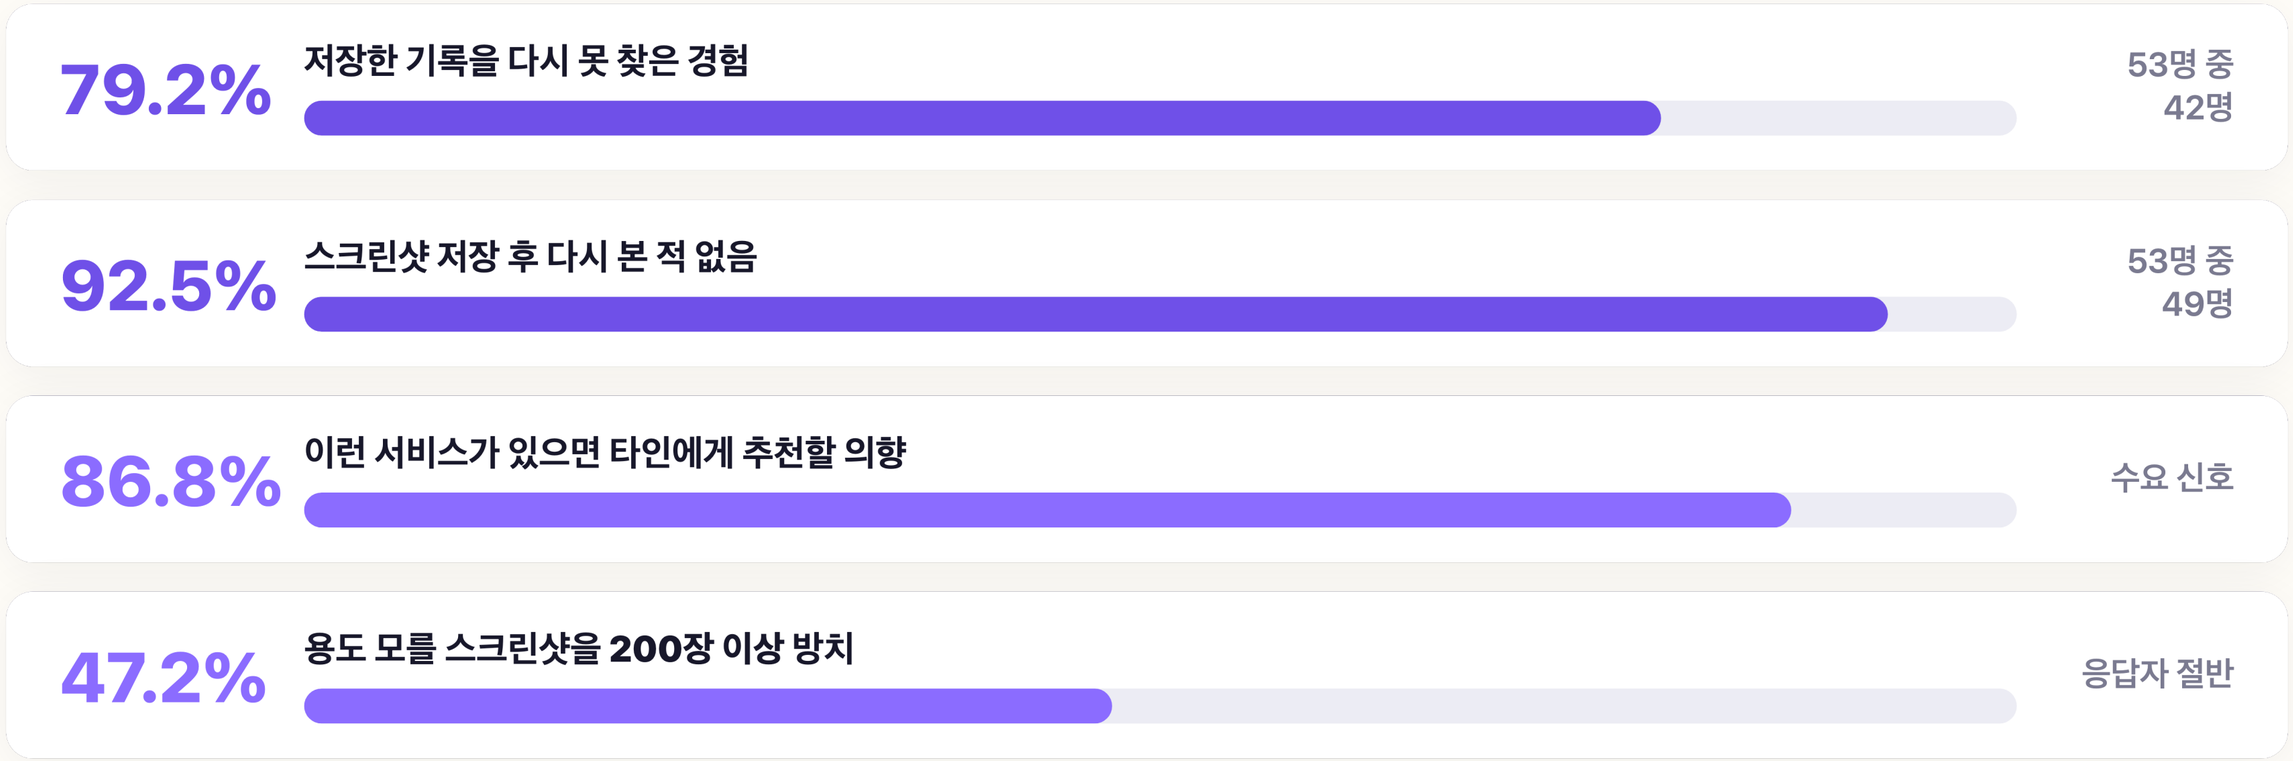

출처 · 자체 설문 (20대 53명 · 2026.6.29~7.3, n=53) · 본편 3p에서는 79.2% · 92.5% 두 지표만 사용

부록 · 문제 검증

“누구의 문제인가요?”

설문 뒤에는 두 사람이 있습니다 — 못 찾는 사람과, 떠올리지 못하는 사람

김소중 24세 · 대학생

Problem 1 · 찾기

“분명 저장했는데, 어디 뒀지?”

저장했다는 건 아는데, 필요한 순간엔 다시 못 찾습니다. 기록이 앱마다 흩어져 있어 어디서 봤는지조차 헷갈립니다.

- 카톡 나에게 보내기
- 사진 앱
- 유튜브 나중에 볼 동영상
- 인스타 저장

김단국 29세 · 개발자

Problem 2 · 떠올리기

“예전에 비슷한 걸 저장했던 것 같은데…”

저장했다는 사실 자체를 잊어버립니다. 검색창조차 열지 않고, 결국 같은 자료를 처음부터 다시 찾습니다.

- 읽으려 담아둔 아티클
- 공식문서 · 릴리스노트
- 자동화 레퍼런스

두 문제 = 찾기(Chat) · 떠올리기(Reminder) — 모찌의 두 에이전트가 하나씩 맡습니다 · 자체 설문 응답에서 도출한 페르소나

부록 · 기대효과

“그래서 뭐가 좋아지나요?”

세 가지 숫자를 목표로 두고, 전부 이벤트 로그 · 코호트로 측정하도록 설계했습니다

01 · 탐색 시간

66% ↓

흩어진 기록을 다시 찾는 시간

검색 성공률 85% · 측정: 검색 시작→기록 열람 구간 이벤트 로그

02 · 저장 정보 재활용

60% ↑

저장 후 30일 안에 다시 활용

현재는 92.5%가 다시 안 봄 · 측정: D7 · D30 코호트 재열람율

03 · 회수율 · 모찌의 핵심

75% ↑

기억 못 해도 먼저 떠올려주는 알림 확인율

추천 기록 확인 60% · 4주 잔존 25% · 측정: 알림 발송→24h 내 열람

BEFORE 저장 → 방치 → 검색 스트레스 → **AFTER** 저장 → 자동 정리 → 필요한 순간 먼저 회수

부록 A1 · 아키텍처

“실제로 다 구현된 건가요?”

세 층 전부 구현 · GCP 서울에서 라이브 운영 중 · 자동 테스트 788개가 커밋마다 검증합니다

iOS 앱

· 저장 입력 3종: 백탭 · 공유시트 · 직접 메모

· 온디바이스 민감정보 감지 (Vision OCR + 룰)

· 캘린더 · 미리알림 연동 (EventKit)

SwiftUI · TCA · Realm

백엔드

· API 서버 + 비동기 분석 워커 분리

· Apple / Google 로그인

· API 37개 · 단일 openapi.json 계약

FastAPI · SQLAlchemy · GCP 서울

데이터 · AI

· Postgres 16 + pgvector · GCS

· Gemini 3.1 Flash Lite · voyage-4-large · rerank-2.5

· Tavily · Naver · YouTube · APNs

Vertex AI · pgvector

저장 1건의 경로 캡처 → 기기 내 민감정보 검사 → 업로드 · 즉시 접수 → 워커 분석 (에이전트 루프) → 색인 · 알림 계획

GCP 서울 · HTTPS 라이브 · 월 약 $50

자동 테스트 788개 (서버 560 · 앱 228)

openapi.json 하나를 앱 · 웹 · 서버가 공유 → 세 표면이 서로 어긋날 수 없는 구조

부록 A1 · 저장 · 캡처

“백탭 못 쓰면요? 안드로이드는요?”

저장 경로는 3종으로 이중화 — 백탭이 안 돼도 공유시트 · 직접 저장으로 언제나 남깁니다

주 경로

백탭

아이폰 뒷면 두 번 톡 · iOS 손쉬운 사용 트리거 · 보던 화면을 무의식적으로 저장

폴백 ①

공유시트

어떤 앱에서든 공유 → 모찌 · 백탭 미지원 기기· 구형 기종을 그대로 커버

폴백 ②

직접 저장

앱 안에서 스크린샷 · 링크 · 메모 직접 추가 · 기존 갤러리 일괄 가져오기

안드로이드 정리 · 검색 · 회수 로직은 서버 쪽 **플랫폼 독립** — 입력 어댑터(빠른 설정 타일 · 공유시트)만 교체하면 확장. 로드맵 A12에 명시.

부록 A2 · 아키텍처

“AI가 화면을 어떻게 이해하나요?”

5단계 파이프라인 안에서, 모델이 부족한 정보를 도구 4종으로 직접 채워 이해합니다

1
수집 · 정규화
Idempotency로 중복 저장 방지

→

2
컨텍스트 조립
사용자 저장 패턴 · 기존 카테고리 주입

→

3
에이전트 루프
모델이 필요한 도구를 골라 호출

→

4
기록 반영
분류 · 요약 · 일정 · 할 일 생성

→

5
임베딩 색인
요약+태그 입력 · 의미 벡터 저장

도구 1
링크 본문 수집
URL 본문을 가져와 요약에 반영

도구 2
웹 근거 검색
화면만으로 부족한 사실을 보강 (Tavily)

도구 3
원본 영상 복원
영상 캡처에서 원본 영상 링크 복원

도구 4
장소 정보 연결
네이버 지역검색 + Google Places 300m 교차 검증

부록 A2 · Analysis 도구

“화면 한 장으로 그걸 다 아나요?”

모델이 부족한 정보를 도구 4종으로 직접 채웁니다 — 화면 밖의 사실까지 끌어옵니다

도구 1 링크 본문 수집

공유 URL에서 플랫폼 메타(제목·작성자·길이)와 페이지 본문을 읽어 요약·할 일 추출에 넣습니다.

`platformContext` `webFetch`

도구 2 웹 근거 · 참고 링크

화면만으로 부족한 사실은 Tavily로 검색해 보강하고, **원본 > 공식 > 편집샵** 순으로 대표 링크를 고릅니다.

`webSearch` `findReferenceUrls`

도구 3 원본 영상 복원

영상 캡처의 제목·채널명으로 원본을 검색하고, 없으면 채널 내부를 뒤져 못 찾으면 채널 링크로 폴백합니다.

`recoverYoutubeUrl` `YouTube Data`

도구 4 장소 정보 연결

장소명을 네이버 지역검색으로 주소·좌표화하고, **300m 이내** 교차 확인 후 Google Places로 별점·리뷰를 보강합니다.

`searchPlaceGeo` `Naver · Google Places`

모든 외부 호출은 SSRF 가드(사설망 차단 · MIME 제한 · 2MB 상한)를 통과합니다 · 출처 mochi-backend 수집·정규화 워커 (SSRF 가드 구현)

부록 A3 · 아키텍처

“챗봇이 지어내서 답하지 않나요?”

내 기록 검색이 항상 먼저 · 찾은 근거만 인용 · 데이터 변경은 반드시 사용자 확정을 거칩니다

세션 · 컨텍스트 정책

- 30분 비활성 시 세션 분리
- 최근 **20개 메시지** 윈도우 유지
- 최대 **5라운드 · 8 tool-call** 상한
- SSE 스트리밍으로 응답 즉시 표시

근거 · 실행 정책

- **내 기록 검색이 항상 우선**, 없을 때만 웹 검색
- 답변마다 원본 기록 인용 첨부
- 데이터 변경은 전부 **제안 카드 → 사용자 확정** 후 실행
- 확정 시 아이폰 캘린더 · 미리알림까지 등록

실행 흐름 "내일 알림 잡아줘" → 제안 카드 표시 → 사용자 확정 → **알림 · 캘린더 등록**

부록 A4 · 아키텍처

“알림이 스팸이 되지 않나요?”

병합 · 억제 게이트가 발송 전 모든 알림을 걸러내고, 열람 반응이 다음 회차를 줄입니다

1
후보 선별
마감 · 잊혀질 시점의 기록 선별

→

2
플랜 수립
마감 역산 · 문구 · 횟수 결정

→

3
병합 · 억제 게이트
같은 날 묶음 · 6시간 이상 간격 · 과알림 억제

→

4
발송 워커
APNs 푸시 발송

피드백 루프

알림을 **언제, 어떤 주제로** 열었는지가 다음 회차의 시각 · 주제 선정에 반영됩니다.

사용자 통제

전역 알림 on/off, 항목별 알림 끄기, 알림 시각 옮기기를 제공합니다.

부록 A4 · Chat · Reminder 도구

“대답하고 알림 잡는 건 어떻게 동작하나요?”

조회는 내 기록이 항상 먼저, 데이터 변경은 반드시 제안 카드 → 사용자 확정을 거칩니다

Chat 도구

`search_items · get_item_detail · view_item_image`

기록을 먼저 조회 — 하이브리드 검색으로 키워드가 달라도 찾고, 이미지를 LLM이 직접 봅니다.

`web_search · web_fetch`

기록에 없을 때만 웹에서 최신 정보를 보강합니다.

`propose_* (제안 카드)`

일정·기록 변경은 확인 카드로 분리 — 사용자 확정 후에만 실제 실행됩니다.

최대 5라운드 · 8 tool-call | SSE 스트리밍

Reminder 도구

`get_scheduled`

그날 예약된 알림을 먼저 조회해, 겹치면 하나로 묶습니다.

플랜 결정 · 규칙 + LLM

intent별 후보는 규칙 코드로, 문구·시각·횟수는 gemini-3.1-flash-lite가 결정합니다.

겹침 방지 게이트

6시간 이상 간격 · 마감과 겹치면 다음날로 · 같은 날 여러 건은 묶음.

마감 전 미리 · 잊을 때쯤 다시 | APNs 예약 발송

SSE 이벤트 `message_delta` `tool_started` `citation` `proposal` `done` · 출처 mochi-backend openapi.json · Chat SSE 스트리밍 스펙

부록 A4 · 회수 품질

“때를 어떻게 알고, 엉뚱한 걸 안 들이미나요?”

‘언제·무엇을’은 트리거 + 정밀도 게이트로 판단 — 확신 낮으면 알림 대신 피드로만

① 언제 — 트리거 신호

날짜 임박 (청첩장 D-3) · 위치 근접 · 재방문 맥락 · 유사 저장 반복

후보를 넓게 잡되, 발송은 좁게 — 발송 전 병합·억제 게이트(A4)를 한 번 더 통과

② 무엇을 — 정밀도 우선

Precision-first 임계값. 확신이 낮은 후보는 알림을 쏘지 않고 홈 피드에만 담아, ‘조용한 회수’로 남깁니다.

놓친 회수(재현율)보다 **잘못된 회수(정밀도)**를 먼저 막는 쪽으로 설계

목표 · 24h 확인율 75% 열람 · 무시(dismiss) 피드백으로 개인별 임계값을 자동 조정 — 알림 planner A/B는 A6-2에서 실측

부록 A5 · 검색

“일반 검색과 뭐가 다른가요?”

키워드만으로는 단어가 다르면 못 찾고, 벡터만으로는 상위 순위 품질이 약해 — 둘을 융합하고 리랭커로 재정렬했습니다

키워드 BM25 · 상위 80건 + 의미 벡터 voyage-4-large 1024차원 (HNSW) · 상위 80건 → RRF 융합 (k=60) → **rerank-2.5 재정렬**

리랭커 효과 · 자체 실측 · 코퍼스 391 · 질의 24

R@3 상위 3개 회수율	0.476 → **0.872**
MRR 평균 역순위	0.560 → **0.882**
Recall@10	0.990 → 1.000 (이미 포화)

전체 recall은 거의 포화 — 리랭커는 엄격한 상위 순위 품질을 개선

조회 폭 확장 · 코퍼스 1,045 · 질의 50

recall@8	0.800
recall@25	**0.958**

후보 폭을 8→25건으로 넓혀 정답 누락을 줄임

검색 파이프라인 비교

채택 **임베딩 모델 · 필드**

질문 — 어떤 모델·입력이 상위 순위를 가장 잘 세우나? **46 문서 · 30 gold query**

→ **voyage-4-large@1024 × 요약+태그** · nDCG@5 0.925 · HitRate@3 1.000 · MRR 0.944

채택 **reranker**

질문 — 같은 후보에서 rerank가 상위 순위를 개선하나? **391 문서 · 24 gold query**

→ Vector→+rerank-2.5 · **R@3 0.476→0.872** · MRR 0.560→0.882 · BM25/hybrid는 추가 recall 없음

보조 **후보 수 TOP_K**

질문 — 후보 폭을 넓히면 누락이 주나? **1,045 item · 50 query · 감사 라벨**

→ TOP_K 8→25 · **recall@8 0.800→recall@25 0.958 (+15.8%p)** · 구조적 효과라 보조 근거

기각 **채택하지 않은 전략**

semantic expansion nDCG 0.925→0.909 · category 필드 0.701→0.693 (Δ-0.008)

semantic-gap **진단셋(21 query)**에서 BM25 nDCG@5 0.021 vs Vector 0.798 — 일반 검색 성능 아님

자체 실측 · gold eval — lab/archive/rag-search · rag-rerank-eval · lab/active/rag-topk-eval의 FINDINGS.md

How we evaluated

평가 방법론

핵심은 하나 — 채점하는 쪽과 채점당하는 쪽을 분리했다. self-grading을 하지 않았다.

정답 만들기

정답은 사람·독립 주체가

골든 케이스는 평가 대상(Gemini)과 다른 주체가 저작하고 팀이 리뷰 · 날짜 정답은 스크립트가 실제 2026 달력과 전수 대조(LLM 아님) · 이미지 정답은 사람이 기입한 저장 의도

LLM-as-judge | Human judge

채점은 하되, 판정 모델 ≠ 대상 모델 + Human in the loop

RAG 정답은 생성(flash-lite)과 다른 모델(opus)로 독립 재감사(demote 43·promote 21) · 알림·이미지 적합도도 judge로 채점하고 규칙 baseline과 교차검증 → 순환(self-grading) 차단

통계

주장은 보수적으로

모든 수치에 Wilson 95% CI 병기 · 반복 run은 비독립이라 케이스 단위로 보수 집계 · 핵심 A/B는 McNemar exact 검정(p=0.000488)

한계 공개

약점을 먼저 말한다

category false reuse 4/16 · 알림 순서 안정성 저하 · 공휴일 날짜 파싱 실패 · category 다중평가자 blind annotation은 하지 않음

프로덕션 프롬프트·스키마를 직접 import해 같은 골든셋을 반복 실행 → 운영과 평가 사이 drift 0

분석 품질과 회귀 평가

채택 · v29 골든 eval

229 cases × 3회 = 687 scoring runs · 전체 **95.6%** (Wilson CI 93.8~96.9)

clear n=135	**99.5%** CI 98.2~99.9
boundary n=48	**93.1%** CI 87.7~96.2
date n=40	**91.7%** CI 85.3~95.4
table n=6	**strict 55.6% · recall 100%**

표 strict는 약점 — 후속 보완 항목으로 공개

채택 extraction 전략

22 스크린샷 + 40 텍스트 메모

hybrid C + gemini-3.1-flash-lite · 텍스트 의도 92% · ≈$0.00014/건 (flash C 88% · ≈$0.00051)

이미지는 gold 의도 정확도 없음 — 스크린샷까지 92%로 표기하지 않음

채택 intent schema

intent F1 0.809 → 0.935 — applicability threshold 설계를 뒤집고 intent_instances 테이블·lifecycle 채택

일정 probe: Dacon v23→v25 결과추출 0/5→3/5 (v26 회귀로 기각) · boundary v29b 채택

gold eval · 프로덕션 프롬프트/스키마 직접 import — mochi-backend/eval/REPORT.md · extraction-strategy · intent-schema-decision FINDINGS.md

Recall과 개인화 정책 비교

채택 · trade-off **알림 planner A/B** 38 cases · 152 LLM calls	dead-hour **34→0** · 일일 최대 **13→7** · 전체 알림 70→58 · gold exact 3/7→5/7. **단, B의 실행 순서 안정성은 저하**(A exact 1.0 vs B 순서민감 0.053) → 과부하·시간대 품질을 택하고 순서 안정성은 후속 과제로 남김
채택 **proactive bundling** 실데이터 103 item · 103 calls	LLM 6개 테마 중 5개 purity 1.0 · 1개 0.83. 단일 cosine threshold는 한 클러스터가 **93건을 흡수(magnet collapse)** → **embedding prefilter + LLM assignment** 채택, 단일 threshold 기각. grouping은 보조 기능으로 유지
채택 · trade-off **category consistency** live A/B 25 cases · 100 calls	이름 재사용 exact **0/24→24/24** · unique 0/12→12/12 (McNemar p=0.000488). **false reuse 0/16→4/16** → 전체 이력을 약한 힌트로 주고 월간 repair, 추가 LLM/cron 없이 관리

자체 실측 · 프로덕션 파생 실데이터 — recall-notification-planner · proactive-recall-bundling · category-consistency-eval

부록 A6 · 기타 결정

기타 채택 · 기각 기록

보완 중 **shopping product link**

합성 → 실제 97 record · 39 스크린샷 확장. 링크/finder 효용과 실패 유형 함께 기록 · searched 비용 ≈$0.001763 (성공률만 과장 안 함)

best-effort **capture URL 복원**

YouTube best-effort · X/Threads 프로필 경로 중심. X의 cloud-IP 경로는 미검증·취약 → "URL 완전 복구"로 표현하지 않음

기록 **역사 실험**

image agent eval · usermemo regression · chat memory injection · aspect-ratio probe · YouTube enrich — 각 검증 질문/결과/채택·기각/한계 한 줄로 보존

하네스 **평가 방식**

프로덕션 프롬프트·스키마를 직접 import하고 같은 골든셋을 반복 실행해 회귀를 확인 — 한 번 재고 끝내지 않습니다

합성 코퍼스 · 프로덕션 파생 실데이터 · 역사 실험 기록 — docs/CHANGELOG.md 및 각 lab FINDINGS.md

부록 A6 · 개인화

“처음엔 데이터가 없는데 개인화가 되나요?”

데이터 0에서도 기본 정책으로 완전 동작 — 개인화는 그 위에 얹히는 품질 레이어

Day 0 · 콜드스타트

범용 기본 정책

카테고리 · 검색 랭킹 · 알림 시각 모두 기본값. **저장 · 정리 · 검색은 첫 장부터 완전 동작.**

~2주 · 신호 축적

개인 가중치 학습 시작

저장 · 검색 · 열람 · 무시 로그로 자주 쓰는 카테고리와 시간대를 파악.

이후 · 정착

개인 패턴에 수렴

분류 · 검색 랭킹 · 알림 타이밍이 나에게 맞춰짐 (본편 p.19 개인화).

콜드스타트에도 핵심 경험은 완전 동작 — 개인화는 ‘있으면 더 좋은’ 레이어라 초기 이탈 위험이 낮습니다

부록 A7 · 프라이버시

“화면을 통째로 올리는데 개인정보는요?”

가림은 기기에서 굽고 올립니다 — 서버에는 민감 원본이 아예 존재하지 않습니다

기기 내 감지 · 스코어

Apple Vision OCR + 결정론적 룰. 주민번호 · 카드번호(Luhn 검증) · 계좌 · OTP · API 키 · 진료 · 급여를 감지해 **0~10 민감도 스코어**를 매기고, **6점 이상이면 경고 시트**를 띄웁니다.

주민번호 · 카드 Luhn · 계좌 · OTP · API 키 · 진료 · 급여

처리 · 삭제 정책

- 가림 선택 시 **기기에서 블러를 구워 업로드** — 서버 원본 자체가 안전
- 분석용 OCR 텍스트는 추론 직후 **서버 · 단말 양쪽 삭제**
- OCR 텍스트는 검색 · 색인에 미투입
- 채팅 웹 검색에 기록 원문 전송 금지

부록 A8 · 신뢰성

“장애나 공격에는 안전한가요?”

장애 · 중복 · 공격 각각에 가드를 두고, CI 게이트를 통과해야만 배포됩니다

중복 저장 방지

Idempotency-Key로 같은 캡처의 이중 저장 차단

요청 추적 · 에러 규격

요청 추적 ID · 통일된 에러 응답 규격

SSRF 가드

WebFetch에 사설망 IP 차단 · MIME 제한 · 2MB 상한

모듈 경계 강제

아키텍처 경계를 테스트로 강제해 회귀 방지

워커 수평 확장 안전

FOR UPDATE SKIP LOCKED로 작업 이중 처리 방지

테스트 788개

서버 560 · 앱 228, 커밋마다 실행

CI 게이트 lint → 타입검사 → 마이그레이션 → 테스트

부록 A9 · 데모

“심사 당일 네트워크가 끈기면요?”

폴백을 이중으로 두어, 네트워크 상태와 무관하게 5분 여정이 끝까지 완결됩니다

랜딩 → 페르소나 → 기록 → 홈 → 검색 → 질문 → 리마인드 → **마무리**

라이브와 같은 응답 규격

채팅 · 검색 · 라이브 분석 3개 네트워크 요청 모두 실제 서버와 같은 응답 규격으로 동작합니다.

폴백 이중화

심사 당일 네트워크 상태와 무관하게 5분 여정이 끝까지 완결되도록 폴백을 이중으로 두었습니다.

부록 · 사용자 이용 흐름

“전체 화면 흐름이 어떻게 되나요?”

한 번의 온보딩 뒤, 저장 → 정리 → 찾기 → 회수가 아홉 단계로 돕니다

1 온보딩 → 2 백탭 저장 → 3 홈 피드 → 4 기록 상세 → 5 알림 → 6 캘린더 → 7 검색 → 8 채팅 → 9 월간 리포트

본편 미수록

① 온보딩 튜토리얼

시작 안내 → 단축어(백탭) 추가 → 백탭 연결 → 캘린더 연동을 한 번에 설정

본편 미수록

④ 기록 상세

원본·제목·장소 지도·평점·관련 링크·모찌 요약·비슷한 기록을 한 화면에

본편 미수록

⑨ 월간 리포트

한 달 기록이 자동 분류로 발행 · '전체 보기'로 카테고리 카드 탐색

전체 화면은 데모웹(A9)에서 라이브로 시연 · 출처 mochi-ios 실화면 · 데모웹

부록 · 활용 시나리오

“실제로 어떻게 쓰나요?”

캡처 한 장이 마감 알림 · 약속 코스 · 맛집 정보로 바뀝니다

과제 공지

공지를 캡처하면 마감 일정·할 일이 자동 정리되고, 언제 알림이 올지까지 미리 확인됩니다.

공지 캡처

↓

마감·일정·할 일 정리

↓

마감 전 알림 확인

청소용품 · 약속

저장해 둔 기록을 검색으로 바로 찾고, 챗봇에게 물으면 저장 기록을 근거로 대답해 줍니다.

기록을 저장한다

↓

검색으로 바로 찾는다

↓

챗봇에게 물어 활용

맛집 게시물

게시물을 저장하면 장소 지도·평점·관련 링크·요약이 한 화면에 자동으로 모입니다.

게시물을 저장한다

↓

장소·평점 자동 인식

↓

지도·링크·요약 확인

출처 · mochi-ios 실화면 (기록 상세)

부록 A10 · 사업

“돈이 되나요? 지속 가능한가요?”

유료 1인 변동비 ₩260 → ₩990 요금제로도 공헌이익률 88%가 나오는 구조입니다

TAM · 글로벌 노트 · 기록 앱

₩20.0조

SAM · 국내 20~30대 유료

₩276억

SOM · 3년차

₩2.16억

유료 8,000명 × ₩2,245 × 12개월

요금제

FREE ₩0 | LITE ₩990 | PRO ₩2,900 | MAX ₩4,900

유료 1인 변동비 ₩260 · 공헌이익률 88% · 운영비 월 5만원대

30일 잔존 목표 20%

앱 평균 7%의 2.9배. 먼저 떠올려주는 리마인드 루프가 재방문을 만드는 구조입니다.

부록 A10 · 성장 전략

“어떻게 유료 사용자까지 도달하나요?”

오가닉으로 심고 리마인드 루프로 남깁니다 — 30일 잔존 20%, 앱 평균의 2.9배 목표

유입 퍼널 · 12개월 목표

0~6개월 · 오가닉

20대 집중 · iOS 우선, 대학 커뮤니티·숏폼 콘텐츠 시딩 (18~29세 아이폰 60% · 추천 의향 86.8%)

6~12개월 · 유료 확장

Apple Search Ads 검색 광고 유입 · 12개월 LTV ₩23,820 > 유료 1인당 허용 CAC ₩5,700

출처 · Adjust 리텐션 벤치마크 · RevenueCat 2025 State of Subscription Apps · 자체 코호트 목표

부록 A10 · 매출 계획

“3년 뒤 그림은요?”

MAU 1만 → 4만 → 10만, 연 환산 매출 ₩0.22억 → ₩0.86억 → ₩2.16억

12개월 LTV ₩23,820 · 허용 CAC ₩5,700 · LTV / CAC 4.2× · 공헌이익률 88% · 출처 자체 단위 경제성 모델

부록 A10 · 경쟁 우위

“이미 있는 것들과 뭐가 다른가요?”

화면 전체 저장 · 자동 4-Intent 정리 · 먼저 떠올려주는 회수 — 셋을 하나로 묶은 건 모찌뿐

	모찌	사진 앱 검색	스크랩 · 노트 AI
화면 전체(앱·링크·문서) 저장	●	사진만	◐
저장 즉시 자동 정리 (4-Intent)	●	×	수동
먼저 떠올려주는 회수(Reminder)	●	×	×
앱 경계 없는 통합 검색	●	◐	◐

MOAT 셋의 결합 = ‘저장’을 넘어 **떠올려주는** 경험. 쓸수록 개인화(A6-4)로 강해져 전환 비용이 커집니다.

부록 A10 · 원가 구조

“화면마다 멀티모달 돌리면 원가 감당되나요?”

네 가지로 추론비를 눌러 유료 1인 변동비 ₩260 · 공헌이익률 88%

① 비동기 배치

저장은 즉시, 무거운 분석은 뒤에서 묶어 처리 → 피크 분산 · 저비용 시간대 활용

② 모델 라우팅

쉬운 화면은 경량 모델 · OCR, 복잡한 것만 멀티모달 (Vertex AI)

③ 캐싱 · 중복 제거

동일 · 유사 화면 재분석 skip · 임베딩 재사용으로 반복 호출 제거

④ 온디바이스 선처리

민감정보 감지 · OCR은 기기에서 → 서버 호출 · 업로드 대상 축소

88% 공헌이익률
ARPPU ₩2,245 기준

요금제 티어의 사용량 상한으로 헤비유저 원가를 방어 · 출처 자체 단위 경제성 모델 (Vertex AI · voyage 단가 기준)

부록 A11 · 출처

“외부 자원과 라이선스는요?”

AI · API · 오픈소스 · 학술 출처 전부를 문서로 관리하고 라이선스를 병기합니다

AI 모델

Gemini 3.1 Flash Lite (Vertex AI) · voyage-4-large · rerank-2.5

외부 API

Tavily · Naver 지역검색 · Google Places · YouTube Data · Apple Vision · APNs

오픈소스 · 라이선스 병기 관리

TCA · Realm · FastAPI · SQLAlchemy · pgvector · Next.js

학술 · 데이터 출처

학술 4건 · 데이터 출처 7건. 인용 검증 기록은 docs/appendix-sources.md에서 관리합니다.

부록 A11 · 학술 · 오픈소스

“그 수치와 라이브러리, 출처가 있나요?”

문제 정의의 숫자는 논문 4건에서, 코드는 라이선스를 병기한 오픈소스에서 왔습니다

학술 연구 · 4건

40% 저장한 사진을 다시 못 찾음 · **Whittaker et al. (2010)**, Personal and Ubiquitous Computing

하루 기억은 하루 안에 가장 크게 사라짐 · **Murre & Dros (2015)**, PLOS ONE

58% 웹 방문의 절반 이상이 재방문 · **Tauscher & Greenberg (1997)**, IJHCS

수 분 모바일 알림은 대부분 수 분 안에 확인 · **Pielot et al. (2014)**, MobileHCI

오픈소스 · 라이선스 병기

iOS · SwiftUI

TCA · MIT · Realm · Apache-2.0 · Kingfisher · MIT · NMapsMap

백엔드 · Python 3.12

FastAPI · MIT · google-genai · SQLAlchemy · MIT · pgvector · httpx · structlog

웹 데모 · TypeScript

Next.js · MIT · React · MIT · Tailwind · Three.js · R3F · Motion · lucide

데이터 출처 7건(시장·인구·CPI·리텐션·CAC 등)과 인용 검증 기록은 docs/appendix-sources.md에서 관리